



Thinking vs. Doing: Test-Time Interaction(TTI)으로 에이전트 추론 확장하기

행동을 통한 정보 탐색이 어떻게 WebVoyager & WebArena SOTA를 달성했는가

THINKING (Deep Test-Time Compute)



DOING (Test-Time Interaction)



WebVoyager & WebArena SOTA Achievement
through Active Information Exploration

The Shift (패러다임의 전환)



에이전트의 성공은 '한 번에 얼마나 깊게 생각하는가(Thinking)'가 아니라, '얼마나 유연하게 행동하고 새로운 정보를 탐색하는가(Doing/Interaction)'에 달려 있습니다.

기존 LLM의 단일 스텝 연산량 증가(TTS)를 넘어, 상호작용 단계(Interaction Steps) 자체를 스케일링하는 새로운 접근법을 제시합니다.

The Solution (해결책: TTI)



단순 프롬프팅을 넘어선 Curriculum-based Online RL (TTI) 도입.

에이전트의 허용 상호작용 길이(Horizon)를 승수적(Multiplicative)으로 점진 확장하여, 얕은 활용(Exploitation)부터 깊은 탐색(Exploration)까지 스스로 학습하게 만듭니다.

The Result (SOTA 달성)




Gemma 3 12B 모델만으로 압도적 성능 증명.

WebVoyager 64.8%, WebArena 벤치마크에서 오픈 가중치/오픈 데이터 기반 최고 성능(SOTA) 달성.

폐쇄형(Closed) 모델들과 대등하게 경쟁하는 수준으로 도약.


The Agentic Reality Matrix: 정적 지식 풀이 vs. 동적 환경 적응



Insight: 행동(Action)해야만 세상(State)이 변하고 새로운 정보(Information Gain)가 주어짐.
훈련 시점에 완벽한 경로를 외워도 실전에서는 소용이 없음. '반응형(Reactive)'에서 '적응형(Adaptive)'으로의 진화 필수.


The Limit of “Thinking More”: 방 안의 철학자 vs. 밖으로 나간 탐험가

Test-Time Scaling (TTS): 깊이 파고들기




- 단일 스텝 내의 연산량만 증가 (예: CoT 길이 연장, Best-of-N).
- 호텔 예약 시 '첫 페이지만 100번 분석하기'와 같음.
- 환경과 상호작용하지 않으므로 새로운 정보(Information Gain) 획득 불가.

Test-Time Interaction (TTI): 넓게 탐색하기 (Our Approach)



- 단일 롤아웃 내 상호작용 단계(Horizon)의 확장.
- 클릭하고, 스크롤하고, 원하던 결과가 아니면 뒤로가기(GoBack)를 수행하며 동적으로 계획을 수정.
- 더 많은 행동(Doing)이 더 많은 정보와 가능성을 만듭니다.

Compute Decomposition: 한정된 자원의 최적 분배 곡선




제한된 Test-Time 토큰(Compute) 예산이 주어졌을 때, 에이전트는 이 예산을 어디에 투자해야 할까요?

- ➔ **수직적 확장 (Per-Step Budget Forcing):**
한 스텝에서 길게 추론하도록 프롬프팅해도 성공률 향상은 미미함 (행동 변화율 15% 미만).
- ➔ **수평적 확장 (Interaction Scaling):**
동일한 컴퓨팅 예산을 여러 단계의 상호작용 (Interaction Steps)으로 분배했을 때, 압도적으로 가파른 성공률(Task Success) 상승 곡선을 보여줌.

» **결론:** 복잡한 에이전트 환경에서는 '한 번 더 깊게 생각하는 것'보다 '한 번 더 행동하고 정보를 얻는 것'의 ROI가 훨씬 높습니다.

훈련의 딜레마: 왜 단순 프롬프팅이나 기존 RL로는 안 되는가?


상호작용 길이(Horizon)를 늘리는 것은 이론적으로 훌륭하지만, 이를 모델에 내재화하는 것은 까다롭습니다.



The Breakthrough: TTI (Test-Time Interaction) 알고리즘


이러한 딜레마를 해결하기 위해, 롤아웃 길이(Rollout Horizon) 자체를 점진적으로 조절하는 Curriculum-based Online RL (Filtered BC)을 도입했습니다.

Phase 1: 얇은 활용 (Exploitation) 학습



- 짧은 궤적(Short trajectories)으로 시작.
- 명확한 정답 경로를 따르는 기본기(Atomic skills)와 목표 달성 능력을 확실하게 다짐.

Phase 2: 깊은 탐색 (Exploration) 확장




- 점진적으로 최대 허용 상호작용 길이(Maximum Horizon)를 증가.
- 에이전트가 실패 시나리오를 마주하고, 뒤로 가기(Backtracking) 및 새로운 검색 등을 통해 스스로 위기를 극복하는 능력을 체득.

» Key Insight: '쉬운 태스크 -> 어려운 태스크'가 아닌, '짧은 허용 시간 -> 긴 허용 시간'으로의 커리큘럼 전환.

Technical Detail: 승수적 스케줄링 (Multiplicative Schedule)

커리큘럼을 확장하는 속도 역시 에이전트의 학습 효율에 결정적인 영향을 미칩니다.



Method	Formula	Description	Task Success Rate
Additive (선형적 증가)	$h_i = \text{clip}(h_{\min} + i, h_{\max})$	너무 보수적인 접근. 에이전트가 지름길(Shortcut)에 과적합될 위험 존재.	29.50%
Multiplicative (승수적 증가)	$h_i = \text{clip}(h_{\min} \times i, h_{\max})$	기본 스킬을 빠르게 습득한 후, 조기에 깊은 탐색(Exploration) 행동에 노출시킴.	32.25%


TTI (승수적 선수적 증가) → (Multiplicative Schedule) 를

TTI는 이 승수적 스케줄링을 채택하여 더 적은 훈련 스텝으로도 고정 길이(Fixed h) 훈련을 증가하는 학습 효율을 달성합니다.

Training Dynamics: 에이전트는 어떻게 '탐색'을 배우는가?


TTI 커리큘럼에 따라 최대 허용 길이(Max Horizon)가 늘어나는 순간(초록색 영역), 에이전트의 행동 패턴이 극적으로 진화합니다.

스텝 길이 증가




성공적인 임무 완수를 위해 더 많은 단계를 거치는 것을 주저하지 않습니다.

탐색 행동의 발현



에러를 만났을 때 능동적으로 뒤로 가기(GoBack)와 새로운 검색(Bing)을 활용하는 비율이 급증합니다.

Overthinking 방지



행동력이 늘어남과 동시에, 단일 스텝 당 사용하는 토큰 수(Reasoning 길이)는 오히려 감소합니다. 스스로 '생각'과 '행동'의 균형을 맞춥니다.

Quantitative Proof: WebVoyager & WebArena SOTA 달성

Gemma 3 12B라는 상대적으로 작은 모델에 TTI를 적용하여, 오픈 모델/오픈 데이터 기준 최고 성능 벤치마크를 갱신했습니다.

WebVoyager Benchmark

SOTA



WebArena Benchmark

SOTA



WebVoyager 64.8%: 기존 오픈 데이터 SOTA 모델 대비 30% 이상 성능 향상. UI-TARS 등 폐쇄형 인간 라벨링 데이터 모델들과 실질적으로 경쟁 가능한 수준.

고정 길이 훈련의 압도: 짧은 고정 길이(Fixed h=10)와 긴 고정 길이(Fixed h=30) 훈련 방식 대비 모든 주요 도메인에서 압도적인 우위를 점함 (녹색 방사형 그래프 영역 참고).

Case Study 1: 복잡한 작업에서의 '적응형 탐색(Adaptive Exploration)'

임무: Allrecipes 웹사이트에서 '평점 4점 이상, 리뷰 50개 이상인 애플파이의 최고 굽기 온도' 찾기.




Insight: 고정된 짧은 Horizon으로 훈련된 모델은 첫 번째 레시피에 갇혀 무한 루프에 빠지는 반면, TTI 모델은 상황에 맞춘 탐색과 백트래킹을 자유롭게 구사합니다.

Case Study 2: 단순한 작업에서의 '전략적 활용(Strategic Exploitation)'


임무: GitHub에서 'Machine Learning 분야 트렌딩 프로젝트' 검색.

Step 1




불필요한 외부 검색 생략

Step 2



Trending 탭으로 직접 이동

Step 3



최단 경로로 임무 완수

Insight: 상호작용 길이를 길게 주었다고 해서 무조건 행동을 낭비하지 않습니다. TTI는 태스크의 복잡도를 스스로 인지하고, 탐색(Exploration)과 활용(Exploitation)의 밸런스를 동적으로 조절합니다.


Limitations & Failure Modes: 한계와 남은 숙제

TTI의 뛰어난 성과에도 불구하고, 에이전트 행동 로그에서 다음과 같은 명확한 한계점들이 관찰되었습니다.



1. 리셋 의존성 (Over-reliance on Resets)

도메인 내에서 오류 발생 시, 세밀한 필터 수정이나 메뉴 재진입 등 국지적인 해결책을 찾기보다 무작정 Bing 첫 화면으로 초기화(Reset)해버리는 경향이 종종 발생합니다.




2. 자체 검증의 한계 (Limited Self-Verification)

'2022년에 생성된 프로젝트'를 찾는 임무에서, 에이전트 스스로 텍스트로 '이것은 2021년 프로젝트다'라고 정확히 인지(Thinking)해놓고도, 마지막 순간에 그대로 정답으로 제출(Doing)해버리는 인지-행동 간 괴리 현상이 관찰되었습니다.

(향후 TTI와 Per-step Reasoning의 결합 필요성 증명)

Industry Context: MiniMax M2.7과 자기 진화(Self-Evolving) 에이전트

TTI 연구가 증명한 'Test-Time 행동력'의 중요성은 현재 산업계 최전선의 SOTA 모델들의 행보와 완벽히 일치합니다.




MiniMax M2.7의 등장:

최근 출시된 M2.7은 단순한 코드 생성을 넘어, 프로덕션 환경의 라이브 에러를 직접 디버깅하고, 스스로 RL 실험 환경을 조작하며 진화합니다.



자율성의 극대화:

100회 이상의 반복 루프를 인간 개입 없이 스스로 수행합니다.



TTI와의 연결점:

TTI가 입증한 '상호작용을 통한 적응력'이 극대화되면, 환경을 탐색하는 수준을 넘어 에이전트 스스로 도구와 코드를 뜯어고치는 '자기 진화(Self-Evolution)'의 영역으로 넘어가게 됩니다.

The Ultimate Synthesis: 뇌(Brain)와 근육(Muscle)의 결합

미래의 자율형 에이전트는 두 가지 Test-Time 차원의 스케일링이 결합될 때 완성됩니다.



Reasoning (Thinking / TTS)

OpenAI o3, MiniMax M2.7의
복잡한 시스템 이해력과
강력한 자체 추론(Per-step
Reasoning), 그리고 자체 검증
(Self-Verification) 능력.

The Self-Evolving Agent



Interaction (Doing / TTI)

불확실성이 높은 실세계
환경에서 끊임없이 부딪히고,
에러를 복구하며, 새로운
정보를 동적으로 획득하는
커리큘럼 기반 행동력.

**The Future: 생각만 하는 AI에서,
행동하며 스스로 진화하는 AI로.**

정적인 추론 스케일링을 넘어, Test-Time 상호작용(TTI)
스케일링이 실세계 AI 배포의 판도를 바꿀 것입니다.



생각만 하는 AI에서, **행동하며 배우는 AI**로.

Q&A